

MindSpore Transformers 大模型系列课程

MindSpore Transformers训推Mcore架构介绍

主讲人：苏海波

昇思MindSpore研发工程师

MindSpore Transformers SIG Maintainer

专题一：套件介绍



《MindSpore Transformers训推Mcore架构介绍》

《MindSpore Transformers环境安装与镜像制作》

专题二：LLM训练

《MindSpore Transformers LLM预训练与微调介绍与实践》

《MindSpore Transformers LLM数据预处理介绍与实践》

《MindSpore Transformers Safetensors权重详解》

《MindSpore Transformers断点续训介绍与实践》

《MindSpore Transformers训练在线监控介绍与实践》

《MindSpore Transformers训练高可用特性介绍》

专题三：LLM推理

《MindSpore Transformers推理介绍与实践》

《MindSpore Transformers & vLLM部署与评测》

专题四：高阶开发

《MindSpore Transformers LLM推理迁移与实践》

《MindSpore Transformers & vLLM推理精度比对》

《MindSpore Transformers LLM训练迁移与实践》

《MindSpore Transformers & Megatron-LM训练精度比对》

《MindSpore Transformers训练性能调优》

《MindSpore Transformers推理性能调优》

《MindSpore Transformers DeepSeek-R1蒸馏实践》

目录

1. MindSpore Transformers上下游整体架构介绍
2. MindSpore Transformers大模型全流程能力一览
3. MindSpore Transformers组件架构介绍
4. MindSpore Transformers训推展示

1. MindSpore Transformers上下游整体架构介绍

MindSpore Transformers上下游组件全景图



2. MindSpore Transformers大模型全流程能力一览

MindSpore Transformers大模型使能套件，全流程开箱即用

对接主流生态能力，0day支持新模型部署

MindSpore Transformers

◆ Mcore支持中 ◆ Mcore支持 ◆ Legacy支持

全流程能力

训练/微调

预训练

低参微调
Lora

SFT微调

评测

AISBench评测工具
20+榜单

OpenCompass评测工具
30+榜单

推理部署

vLLM服务化部署

SGLang服务化部署

量化
A16W8/A8W8/
C8/A8W4

第三方组件：

Hugging Face
Dataset

Megatron-LM
Dataset

AISBench

OpenCompass

vLLM

SGLang

配置管理

预置模型库

大语言模型（稠密/MOE）

DeepSeek

Qwen

GLM

LLaMA

Mixtral

TeleChat

InternLM

Yi

YiZhao

...

多模态模型

Qwen-VL

Llava

Llava-next

mLlama

CogVLM2-Video

CogVLM2-Image

...

高阶并行接口

静态图训练

高阶并行接口

推理加速

高阶并行接口

多维并行

模型并行

数据并行

优化器并行

序列并行

MoE并行

流水线并行(VPP/Seq
PP/ZeroBubbleV)

超长序列并行(Ulysses/Hybrid)

MindSpore

自动微分

自动并行

图算融合

异构并行

内存复用

易用|高效|友好

易用开发

- 新模型0day适配
- 大规模集群任务一键启动
- 低参微调配置化构建，代码零修改

高效可靠

- 训练全流程性能、精度监控
- 大集群训练分钟级故障快恢
- vLLM服务化一键高效部署

生态协同

- Megatron-LM 数据集直接加载
- Hugging Face 数据集、权重、配置参数直接加载
- OpenCompass评测支持中

高性能|高精度

预置大模型

- 50+热门大模型、80+典型规格
- 覆盖稠密、稀疏、多模态理解等领域

并行加速


- 20+高阶训推加速接口
- 8+ 并行算法

高性能算子

- 对接昇腾ATB和ACLNN算子库
- 融合算子优化
- 5+量化算法

3. MindSpore Transformers组件架构介绍

MindSpore Transformers 配置管理组件



关键要素	设计目的
注册机制	通过类工厂形式，注册所有的大模型组件
配置化使能	并使用统一结构的YAML配置文件来组装大模型训练、微调、推理等流程
社区协同对接	支持读取Hugging Face配置文件

```
model:
  model_config:
    vocab_size: 151936
    hidden_size: 5120
    intermediate_size: 25600
    num_hidden_layers: 64
    num_attention_heads: 64
    num_key_value_heads: 8
    head_dim: 128
    hidden_act: 'swiglu'
    max_position_embeddings: 4096
    seq_length: 4096
    initializer_range: 0.02
    rms_norm_eps: 1.e-6
    use_cache: True
    tie_word_embeddings: False
    rope_theta: 1000000.
    model_type: "qwen3"
    architectures: ["Qwen3ForCausalLM"]
    ...
```

YAML配置


```
@MindFormerRegister.register(MindFormerModuleType.CONFIG, legacy=False, search_names='qwen3')
class Qwen3Config(PretrainedConfig):
    def __init__(self,
                  vocab_size=151936,
                  hidden_size=4096,
                  intermediate_size=22016,
                  num_hidden_layers=32,
                  num_attention_heads=32,
                  num_key_value_heads=32,
                  head_dim=128,
                  hidden_act="silu",
                  max_position_embeddings=32768,
                  initializer_range=0.02,
                  rms_norm_eps=1e-6,
                  use_cache=True,
                  tie_word_embeddings=False,
                  rope_theta=10000.0,
                  rope_scaling=None,
                  attention_bias=False,
```

模型配置实例化

```
@MindFormerRegister.register(MindFormerModuleType.MODELS, legacy=False)
class Qwen3ForCausalLM(Qwen3PreTrainedModel):
    def __new__(cls, config):
        if os.environ.get("RUN_MODE") == "predict":
            return InferenceQwen3ForCausalLM(config=config)
        return TrainingQwen3ForCausalLM(config=config)
```

模型实例化

MindSpore Transformers 配置管理组件



关键要素	设计目的
注册机制	通过类工厂形式，注册所有的大模型组件
配置化使能	并使用统一结构的YAML配置文件来组装大模型训练、微调、推理等流程
社区协同对接	支持读取Hugging Face配置文件

```
# HuggingFace file directory
pretrained_model_dir: './Qwen3-32B'
model:
  model_config:
    compute_dtype: "bfloat16"
    layernorm_compute_dtype: "float32"
    softmax_compute_dtype: "float32"
    rotary_dtype: "bfloat16"
    params_dtype: "bfloat16"
```

YAML配置


```
@MindFormerRegister.register(MindFormerModuleType.CONFIG, legacy=False, search_names='qwen3')
class Qwen3Config(PretrainedConfig):
    def __init__(self,
                  vocab_size=151936,
                  hidden_size=4096,
                  intermediate_size=22016,
                  num_hidden_layers=32,
                  num_attention_heads=32,
                  num_key_value_heads=32,
                  head_dim=128,
                  hidden_act="silu",
                  max_position_embeddings=32768,
                  initializer_range=0.02,
                  rms_norm_eps=1e-6,
                  use_cache=True,
                  tie_word_embeddings=False,
                  rope_theta=10000.0,
                  rope_scaling=None,
                  attention_bias=False,
```

模型配置实例化

```
@MindFormerRegister.register(MindFormerModuleType.MODELS, legacy=False)
class Qwen3ForCausalLM(Qwen3PreTrainedModel):
    def __new__(cls, config):
        if os.environ.get("RUN_MODE") == "predict":
            return InferenceQwen3ForCausalLM(config=config)
        return TrainingQwen3ForCausalLM(config=config)
```

模型实例化

MindSpore Transformers 数据集组件



通过DataLoader扩展支持不同数据源，实现不同任务

➤ MindDataset


1. 支持MS原生数据集格式MindRecord，支持预训练，微调场景；

➤ Blended Megatron DataLoader:

1. 与Megatron-LM BlendedDataset功能一致的面向预训练的多源混合数据集；

➤ HF DataLoader

1. 支持在线、离线加载HuggingFace dataset，面向微调场景使用；
2. 支持通过Handler进行数据处理，可进行任意扩展。内置支持Alpaca数据格式处理handler、数据packing handler、可选数据列handler等




支持数据去冗余、EOD压缩等优化特性

➤ **数据去冗余**：在DataLoader层根据并行策略，利用MindSpore数据广播的特性，针对不同RANK返回不同的数据Source，使数据的一致RANK仅有一个RANK获取的到真正的数据，其他RANK配置MockDataLoader，以降低数据集读取IO

➤ **EOD Full/压缩Mask**：在DataLoader层，根据开关配置自动生成针对EOD训练场景的Mask

MindSpore Transformers Mcore模型库组件


——整体架构



MindSpore Transformers Mcore模型库组件

——模型搭建

基于代理模式的Huggingface-Style模型实现




- ①②：训推通用的方法实现，可支持重载
- ①③：训推模型公共定义
- ②④：训推模型独立实现
- ⑤：工厂类获取训推模型



	legacy	Mcore
configuration_deepseek_v3.py	100+	30+
deepseek_model.py deepseek_model_infer.py deepseek_model_train.py deepseek_v3.py	1700+	300
convert_weight.py	900+	0

legacy和Mcore开发DeepSeek V3代码量

基于ModelSpec动态搭建模型



MindSpore Transformers Mcore模型库组件 ——HF社区适配



```

@register_mf_model_parameter(
    mf_model_kwargs=MFModelConfig(
        pad_token_id=151643,
        block_size=32,
        num_blocks=1024,
        normalization='RMSNorm',
        add_bias_linear=False,
        gated_linear_unit=True,
        use_contiguous_weight_layout=True
    ))
@ignore_and_delete_parameter(extra_ignore_param=[
    ('max_window_layers', NotSupportedInfo.useless),
    ('sliding_window', NotSupportedInfo.useless),
    ('use_sliding_window', NotSupportedInfo.useless),
    ('layer_types', NotSupportedInfo.useless),
])
  
```


```

def generate_mapping(self): 1 usage
    mapping_rules = {
        '.linear_q_down_proj': ('.linear_qkv_down_proj', '.linear_q_down_proj', 'q_down'),
        '.linear_kv_down_proj': ('.linear_qkv_down_proj', '.linear_kv_down_proj', 'kv_down'),
        '.linear_q_up_proj': ('.linear_qkv_up_proj', '.linear_q_up_proj', 'q_up'),
        '.linear_kv_up_proj': ('.linear_qkv_up_proj', '.linear_kv_up_proj', 'kv_up'),
        '.linear_q': ('.linear_qkv', '.linear_q', 'q'),
        '.linear_k': ('.linear_qkv', '.linear_k', 'k'),
        '.linear_v': ('.linear_qkv', '.linear_v', 'v'),
        '.linear_kv': ('.linear_qkv', '.linear_kv', 'kv'),
        '.mlp.gating': ('.mlp.linear_fc1', '.mlp.gating', 'gating'),
        '.mlp.hidden': ('.mlp.linear_fc1', '.mlp.hidden', 'hidden'),
        '.mlp.shared_experts.gating': ('.mlp.shared_experts.linear_fc1', '.mlp.shared_experts.gating', 'gating'),
        '.mlp.shared_experts.hidden': ('.mlp.shared_experts.linear_fc1', '.mlp.shared_experts.hidden', 'hidden')
    }

    stacked_params_mapping = []
    for _, mcore_name in self.weight_mapping:
        for pattern, stacked_param in mapping_rules.items():
            if pattern in mcore_name:
                stacked_params_mapping.append(stacked_param)
                break

    return stacked_params_mapping
  
```


MindSpore Transformers 低参微调组件



PetAdapter是所有微调算法适配器的基类，针对于具体的微调算法，一般只需要实现`get\_pet\_model()`接口，将微调算法的改动添加到用户的模型中。

低参微调组件采用适配器设计模式，调用MindPet提供的低参微调算法，在Trainer流程中针对输入模型进行修改适配，然后返回应用了低参算法的模型，进行后续微调训练。

[LoraConfig源码](#)

[LoraAdapter源码](#)

```
# YAML
model:
  model_config:
    pet_config:
      pet_type: lora
      lora_rank: 16
      lora_alpha: 16
      lora_dropout: 0.05
      target_modules: '.*wq|.*wk|.*wv|.*wo'
```

配置YAML

```
def get_pet_model(base_model: PreTrainedModel, config:
Union[dict, PetConfig]):

    pet_type = config.get("pet_type")

    if not PET_TYPE_TO_MODEL_MAPPING.get(pet_type):
        logger.warning("%s doesn't have pet model
currently.", pet_type)
        return base_model
    ...
    # return pet model.
    return PetModel(config=config, base_model=base_model)
```


get_pet_model()




使能LoRA算法



服务化侧注册统一模型



套件库侧分发配置和模型



ModelExecutor

- 接口兼容：对齐vLLM原生社区部署方式，复用服务化特性
- 组件解耦：与服务化层隔离，模型适配和优化聚焦在MF侧完成，复用Mcore接口能力提升泛化性
- 最小化侵入式修改：通过MSAdapter完成PT->MS切换

Config (Hugging Face & vLLM)

Network

MFContext

AutoModel

HF config.json

- model_type
- architectures

- 通过AutoModel将MF模型注册至vLLM，模型适配零代码修改
- 动静态图统一（MSJit），默认使能MindSpore图编译、运行时和融合算子优化，提升开箱即用的推理性能

4. MindSpore Transformers训推展示

第3步：启动微调

- **全参微调**：直接启动训练任务
- **低参微调**：自定义配置Lora等低参算法

```
# model config
pretrained_model_dir: '/data/huggingface/Qwen3-32B'
model:
  model_config:
    compute_dtype: "bfloat16"
  pet_config:
    pet_type: lora
    target_modules: '.*linear_qkv|.*linear_fc1|.*linear_fc2'
```

在线加载HF权重并进行微调

[illegible]

支持vLLM原生接口，一键式启动推理服务

前置准备

1. 下载Hugging Face权重文件

2. 下载openEuler+MindSpore+vLLM推理镜像

服务部署

- vllm serve/entrypoints原生接口，一键式启动OpenAI API 协议推理服务

```
python3 -m vllm_mindspore.entrypoints --model “Qwen3-14B” --trust_remote_code \
--tensor_parallel_size=2 \
--enable-prefix-caching --enable-chunked-prefill \
--max-num-seqs=256 --block-size=32 --max_model_len=70000 \
--max-num-batched-tokens=2048 --distributed-executor-backend=ray
```

```
[root@fyg-0003 workspace]# python3 -m vllm_mindspore.entrypoints vllm.entrypoints.openai.api_server --model "/mnt/data/qwen3_14b" --trust_remote_code --tensor_parallel_size=2 --max-num-seqs=192 --max_model_len=32768 --max-num-batched-tokens=16384 --block-size=32 --gpu-memory-utilization=0.9
```

0 Day适配主流SOTA模型，联创推动社区化开发

- 0 Day模型适配：开源首发Qwen3、DeepSeek-V3-0324/R1-0528、GLM4/Z1、TeleChat2.5、MiniCPM4、GLM-4V等20+规格模型



- 联创：联合北大发布DeepSeek全栈开源推理方案，联合上交发布DeepSeek Int4量化推理方案



□ MindSpore Transformers上下游架构

MindSpore Transformers 南向：基于昇思+昇腾的大模型技术栈，利用昇思框架结合 CANN 对昇腾硬件进行亲和优化，提供高性能的模型训推体验；

MindSpore Transformers 北向：支持MindCluster、MindIE等昇腾平台，也可以被客户第三方平台集成使用。

□ MindSpore Transformers全流程能力

MindSpore Transformers 覆盖大模型全流程：预训练、微调、评测、推理与部署。

MindSpore Transformers 套件特点：易用开发、高效可用、生态协同、高性能、高精度。

□ MindSpore Transformers组件架构

配置管理组件：提供基于YAML配置文件的开发范式。用户无需深入代码，仅需通过一个统一、结构清晰的配置文件，就能轻松完成大模型的训练、微调和推理全流程的组装。

数据集组件：采用任务调度层、数据加载层、数据迭代器层三层设计。支持不同数据源，实现不同任务。支持数据去冗余、EOD压缩等优化特性。

Mcore模型架构：抽象化transformer接口，模型模块化灵活组装，复用Hugging Face config、tokenizer。

低参微调组件：配置化使能不同低参微调算法。

推理服务化组件：使用Hugging Face配置和vLLM CLI即可零感知完成推理部署。

SIG组织

昇思社区

昇腾社区


魔乐社区



课程交流群



MindSpore Transformers SIG群



MindSpore Transformers 内测文档



MindSpore Transformers 开源仓库

SIG > MindSpore Transformers

MindSpore Transformers

https://gitee.com/mindspore/community/tree/master/sigs/mindspore_transformers

MindSpore Transformers SIG (Special Interest Group) 是 MindSpore 开源社区下聚焦 Transformer 类大模型全流程开发与优化的技术团队，涵盖大模型的预训练、微调、推理与部署等关键环节。SIG 团队致力于提升 Transformer 类大模型在性能与易用性方面的表现，推动其在实际场景中的高效应用与落地。

核心成员(6)

Maintainers (2)

- L

Lin-Bert

He Qinglin
- S

suhaibo

Su Haibo

Committers (4)

- C

chenrayray

Chen Xinrui
- H

hss-shuai

Huang Shengshuai
- R

renyujin

Ren Yujin
- Z

zyw-hw

zhang Youwen

会议与活动

工作会议

[查看会议纪要 >](#)

会议时间：每月一次，北京时间周四 16:00 - 17:00 以公开线上会议形式讨论SIG组议题。

会议前3-5天会在邮件列表中发起sig组相关议题收集，并发出会议时间和会议链接。

邮件

dev@mindspore.cn [订阅邮件](#)

最新日程：2025/09/04

2025/09

04

2025/08

07

2025/07

03

MindSpore Transformers SIG月例会

2025-09-04 16:00 - 17:00

会议详情：

发起人：chenrayray

会议时间：16:00-17:00

会议平台：tencent

会议ID：952843996

会议链接：<https://meeting.tencent.com/dm/Fig5yhhFz7E0>

Etherpad链接：<https://etherpad.mindspore.cn/p/sig-MindSpore-Transformers-meetings>

谢谢观看！

MindSpore Transformers训推Mcore架构介绍

MindSpore Transformers 大模型系列课程