

MindSpore Transformers 大模型系列课程

MindSpore Transformers LLM断点续训介绍与实践

主讲人: senzhen 昇思MindSpore研发工程师

专题一：套件介绍

《MindSpore Transformers训推Mcore架构介绍》

《MindSpore Transformers环境安装与镜像制作》

专题二：LLM训练

《MindSpore Transformers LLM预训练与微调介绍与实践》

《MindSpore Transformers LLM数据预处理介绍与实践》

《MindSpore Transformers Safetensors权重详解》

《MindSpore Transformers断点续训介绍与实践》

《MindSpore Transformers训练在线监控介绍与实践》

《MindSpore Transformers训练高可用特性介绍》

专题三：LLM推理

《MindSpore Transformers推理介绍与实践》

《MindSpore Transformers & vLLM部署与评测》

专题四：高阶开发

《MindSpore Transformers LLM推理迁移与实践》

《MindSpore Transformers & vLLM推理精度比对》

《MindSpore Transformers LLM训练迁移与实践》

《MindSpore Transformers & Megatron-LM训练精度比对》

《MindSpore Transformers训练性能调优》

《MindSpore Transformers推理性能调优》

《MindSpore Transformers DeepSeek-R1蒸馏实践》

目录

1. 断点续训概述
2. MindSpore Transformers检查点保存功能简介
3. MindSpore Transformers断点续训支持场景介绍
4. 总结


1. 断点续训概述

断点续训概述

概述：AI 大模型断点续训功能是指在模型训练过程中，由于软硬件故障、网络问题、人工干预等原因导致训练中断时，能够**从中断的地方继续训练，而无需重新开始训练**的功能。

功能原理：断点续训的核心原理是**定期保存模型的训练状态**，即检查点(Checkpoint)，检查点通常包含模型的**权重、优化器的状态、当前的训练步数**等信息。当训练中断时，通过加载最近的检查点，将模型和优化器恢复到中断前的状态，从而继续训练。

重要性：随着 AI 大模型参数规模的不断增大，训练任务的平均持续时间也越来越长，而硬件故障率却随集群规模呈线性增长，断点续训功能**能够有效避免训练进度的丢失，节省大量的时间和计算资源**。



MindSpore Transformers断点续训支持场景列举

续训需求	应用场景
中断续训	集群故障导致任务中断，平台自动基于 最后保存完整的权重 续训或用户 手动指定权重 续训
策略转换续训	修改 模型分布式并行策略 或改变 集群规模 继续训练，如2K卡扩到4K卡，继续训练任务
增量续训	数据集 边生产边训练 ，如一共训练10T数据，每次生产1T数据训练

2. MindSpore Transformers检查点保存功能简介

MindSpore Transformers检查点保存功能简介

概述：在AI大模型的训练过程中，保存模型的权重是至关重要的一步。权重保存功能使得我们能够在训练的任意阶段存储模型的参数，以使用户在训练中断或完成后进行断点续训、评估或推理部署。

目录结构：在训练过程中，MindFormers 默认会在输出目录（默认为 ./output ）中生成权重保存文件夹：**checkpoint**。

8 卡训练任务权重保存格式

```
output_dir
├── checkpoint
│   ├── rank_0
│   ├── meta.json
│   └── {prefix}-{epoch}_{step}.safetensors
.....
└── rank_7
    ├── meta.json
    └── {prefix}-{epoch}_{step}.safetensors
```

8 卡训练任务策略文件保存格式

```
output_dir
├── strategy
├── ckpt_strategy_rank_0.ckpt
├── ckpt_strategy_rank_1.ckpt
├── ckpt_strategy_rank_2.ckpt
.....
└── ckpt_strategy_rank_7.ckpt
```

文件	描述
meta.json	记录 最后保存权重的epoch、step 以及 权重名 ，每个rank进程独立维护一个meta.json文件。
{prefix}-{epoch}_{step}.safetensors	保存的权重文件，包含 网络参数、优化器参数、训练步数 等信息。
ckpt_strategy_rank_{rank_id}.ckpt	保存的分布式策略文件，记录权重的切分信息，主要用于 权重策略转换 。

meta.json内容示例：

{"last_epoch": 10, "last_step": 1, "last_ckpt_file": "qwen3_rank_0-10_1.safetensors"}

3. MindSpore Transformers断点续训支持场景介绍

➤ 中断续训

概述：正常训练**任务异常中断**，需要基于保存的权重重新恢复训练任务。

基于最后保存完整的权重续训

```
load_checkpoint: /path/to/resume/dir  
resume_training: True
```

基于指定step的权重进行续训

```
load_checkpoint: /path/to/resume/dir  
resume_training: prefix-epoch_step.ckpt
```

参数说明

load_checkpoint: 权重路径

resume_training: 续训开关（也可指定为权重名）

应用场景：集群故障导致任务中断，平台自动**基于最后保存完整的权重续训**或**用户手动指定权重续训**

上机演示

详细步骤：

- ① **初始训练：**运行Qwen3【4层】训练，bs=2，dp2-tp2-pp2，一共训练20步，训练到第15步手动停止任务，本次训练会保存第10步权重；
- ② **续训方式1：**基于**最后保存完整的权重**续训，验证从11步开始续训且loss对齐。
- ③ **续训方式2：**指定**第10步权重**续训，验证从11步开始续训且loss对齐。

训练基本配置

```
runner_config:  
  epochs: 1  
  batch_size: 2
```

学习率策略配置

```
lr_schedule:  
  type: CosineWithWarmUpLR  
  learning_rate: 1.5e-5  
  lr_end: 1.5e-6
```

分布式策略配置

```
parallel_config:  
  data_parallel: 2  
  model_parallel: 2  
  pipeline_stage: 2  
  micro_batch_num: 2
```

数据集配置

```
train_dataset:  
  sizes:  
    - 160  
  data_path:  
    - /path/to/dataset
```

权重保存配置

```
callbacks:  
  - type: CheckpointMonitor  
    save_checkpoint_steps: 10  
    keep_checkpoint_max: 3  
    checkpoint_format: "safetensors"
```


➤ 转换策略续训

概述：需要**修改分布式策略**或**扩大/缩小集群规模**继续训练任务，同时需要权重转换。

原分布式策略配置

```
parallel_config:
  data_parallel: 2
  model_parallel: 2
  pipeline_stage: 2
```

修改分布式策略续训
global_batch_size不
变

目标分布式策略配置一

```
parallel_config:
  data_parallel: 2
  model_parallel: 1
  pipeline_stage: 2
```

扩容续训
global_batch_size翻
倍

目标分布式策略配置二

```
parallel_config:
  data_parallel: 4
  model_parallel: 1
  pipeline_stage: 2
```

转换续训

```
load_checkpoint: /path/to/checkpoint
src_strategy_path_or_dir: /path/to/strategy
resume_training: True
auto_trans_ckpt: True
```

参数说明



load_checkpoint: 权重路径

resume_training: 续训开关（也可指定为权重名）

src_strategy_path_or_dir: 策略文件路径

auto_trans_ckpt: 权重自动转换开关

应用场景：2K卡扩容到4K卡续训



global_batch_size翻倍
后，需要训练的**总步数减
半**，学习率曲线**相应压缩
一倍**

➤ 转换策略续训

概述：需要**修改分布式策略**或**扩大/缩小集群规模**继续训练任务，同时需要权重转换。

原分布式策略配置

```
parallel_config:
  data_parallel: 2
  model_parallel: 2
  pipeline_stage: 2
```

修改分布式策略续训
global_batch_size不
变

目标分布式策略配置一

```
parallel_config:
  data_parallel: 2
  model_parallel: 1
  pipeline_stage: 2
```

扩容续训

global_batch_size翻
倍

目标分布式策略配置二

```
parallel_config:
  data_parallel: 4
  model_parallel: 1
  pipeline_stage: 2
```

上机演示

详细步骤：

- ① **修改策略续训**：修改配置为dp2-tp1-pp2，指定加载第10步权重转换续训，任务会**在线合并分布式权重**，验证任务从第11步开始续训且loss对齐。
- ② **扩容续训**：修改配置为dp4-tp1-pp2，加载**合并权重**续训，验证任务从第6步开始续训且loss在合理范围内。

合并的权重会落盘到
output_dir/unified_checkpoint

Tips

- 1、MindSpore Transformers支持**权重策略自动转换**，需准备**权重及其策略文件**，可用于**任意策略**的训练任务；
- 2、MindSpore Transformers支持**加载合并后的权重**，只需准备**权重**，可用于**任意策略**的训练任务；

应用场景：2K卡扩容到4K卡续训

➤ 增量续训

概述：训练数据集**边生产边训练**，当前数据集训练结束后，加入**新生产的训练数据集**继续训练。

预设总训练步数，固定学习率曲线

```
runner_config:
  epochs: 10
  lr_schedule:
    total_steps: 40
```

换新数据集续训

```
load_checkpoint: /path/to/checkpoint
resume_training: True
```

换新数据集续训后再次中断并续训

```
load_checkpoint: /path/to/checkpoint
resume_training: True
```


参数说明

epochs: 总的epoch数

total_steps: 学习率曲线的总步数

load_checkpoint: 权重路径


resume_training: 续训开关（也可指定为权重名）



应用场景：数据分批训练，一共训练10T，每次训练1T数据，直到训完10T。

➤ 增量续训

方式一（推荐✓）



换新数据集续训

```
load_checkpoint: /path/to/checkpoint  
resume_training: True
```


新数据集从中间循环读取

换新数据集续训后再次中断并续训

```
load_checkpoint: /path/to/checkpoint  
resume_training: True
```

新数据集自动基于总步数续训

方式二



换新数据集续训

```
load_checkpoint: /path/to/checkpoint  
resume_training: True  
ignore_data_skip: True
```

新数据集从起始位置循环读取

换新数据集续训后再次中断并续训

```
load_checkpoint: /path/to/checkpoint  
resume_training: True  
data_skip_steps: 10
```

新数据集需要手动计算续训步数

ignore_data_skip: 忽略数据集跳过

data_skip_steps: 设置数据集跳过步数

➤ 增量续训

上机演示

前期准备：数据集1和数据集2

配置：total_steps设置为40步以固定学习率曲线，epoch设置为10

详细步骤：

- ① **训练数据集1：**运行Qwen3【4层】训练，bs=2，dp2-tp2-pp2，一共训练20步，保存第20步权重；
- ② **训练数据集2：**更换数据集2，基于最后保存的权重续训，验证从21步开始续训且loss在合理范围内，训练到第35步左右手动停止任务，保存第30步权重。
- ③ **续训数据集2：**基于最后保存的权重续训，验证续训从30步开始，loss对齐。

Tips

编号	建议
1	各个数据集的数据量 保持均衡 ，如都是1T左右；
2	提前设置total_steps， 固定总的学习率曲线 ；
3	epochs设置 较大值 ，确保能够训完所有数据集； 比如：训练10T数据，每个数据集1T，epochs至少设置为10以上，实际训练10个epoch，整个训练任务就结束了。

注意事项： 更换数据集后，显示的epoch和step可能变化，但是总step数不变。如第1个数据集（20steps/epoch）训练到epoch1-step20结束（总steps=20处结束），换第2个数据集（15steps/epoch）续训，步数显示从epoch2-step6开始（总steps=21处开始），为正常现象。

□ 权重&策略文件保存格式

```
output_dir
├── checkpoint
│   ├── rank_0
│   ├── meta.json
│   └── {prefix}-{epoch}_{step}.safetensors
.....
└── rank_7
    ├── meta.json
    └── {prefix}-{epoch}_{step}.safetensors
```

权重

```
output_dir
├── strategy
├── ckpt_strategy_rank_0.ckpt
├── ckpt_strategy_rank_1.ckpt
├── ckpt_strategy_rank_2.ckpt
.....
└── ckpt_strategy_rank_7.ckpt
```

策略文件

□ MindSpore Transformers支持以下三种场景的断点续训

✓ **中断续训**：正常训练任务中断，需要基于保存的权重重新恢复训练任务。

- 基于**最后保存完整的权重**续训

```
load_checkpoint: /path/to/checkpoint
resume_training: True
```

- 基于**指定权重**续训

```
load_checkpoint: /path/to/checkpoint
resume_training: prefix-epoch_step.safetensors
```

✓ **转换策略续训**：当前训练任务需要迁移到其他规模集群/修改分布式配置继续训练，同时需要权重转换。

- 基于**分布式权重+策略文件**转换续训

```
load_checkpoint: /path/to/checkpoint
src_strategy_path_or_dir: /path/to/strategy
resume_training: True or prefix-epoch_step.safetensors
auto_trans_ckpt: True
```

- 基于**合并权重**转换续训

```
load_checkpoint: /path/to/unified_checkpoint
resume_training: True
auto_trans_ckpt: True
```

✓ **增量续训**：训练数据集**边生产边训练**，当前数据集训练结束后，加入**新生产的训练数据集**继续训练。

- 预设总训练步数，固定学习率曲线

```
epochs: 10
total_steps: 40
```

- 更换数据集续训（二次续训）

```
load_checkpoint: /path/to/checkpoint
resume_training: True or prefix-epoch_step.safetensors
```


断点续训新升级前瞻

- ✓ **新的权重文件保存格式**：按**训练迭代**保存检查点，权重、优化器、切分、续训信息分离保存；
- 优化点：
 - ① 权重实现**端到端转换**，无需合并落盘，**减轻存储压力**同时**极大提升权重转换加载效率**；
 - ② 简化resume_training参数用法，限定为bool值；
- ✓ **高可用模式**：引入**故障恢复**特性，支持**自动断电续存**，直接从断点步数处恢复训练，提升续训效率；
- ✓ **配置简化**：无需auto_trans_ckpt、src_strategy_path_or_dir等配置，提升易用性；

未来升级完成后，将针对更新内容新增课程讲解，敬请期待！

谢谢观看！

LLM断点续训介绍与实践
MindSpore Transformers 大模型系列课程